Árbol tipo C4.5 y bosque aleatorio sobre Heart Disease

Celeste Martin Rodich[1], Matías Emmanuel Machado Benítez[1], Camila Aylen Zeniquel Martinelli[1], Nadine Andrea Peralta Ruiz[1], and Mauricio Nicolás Castro[1]

Universidad Tecnológica Nacional, Facultad Regional Resistencia, Argentina

Resumen El equipo escribió un árbol de decisión al estilo C4.5 y lo enfrentó, bajo un mismo protocolo, a un bosque aleatorio de scikit-learn. El terreno es Heart Disease [3]: las cuatro sedes, 920 pacientes y una clase binaria, ausencia o presencia. La métrica que ordena la comparación es el F1 macro. En 25 particiones estratificadas el bosque alcanza $0{,}8157 \pm 0{,}0308$ y el árbol $0{,}7809 \pm 0{,}0271$. El interés del trabajo no se agota en esa diferencia. Está en las decisiones que permiten leerla: qué se hizo con el faltante, qué se dejó afuera del C4.5 de Quinlan, cómo se eligieron los parámetros sin mirar la prueba, y qué muestra el mismo árbol cuando los datos son discretos, continuos o mixtos.

Keywords: árbol de decisión · C4.5 · random forest · gain ratio · poda pesimista

1. Introducción

Heart Disease se usó durante años para preguntar si un clasificador reconoce la enfermedad coronaria. Casi siempre esa pregunta se hizo sobre una sola sede, Cleveland, la más completa del archivo. Este trabajo abre las cuatro. Al reunirlas aparece lo que una sede sola esconde: 1759 valores ausentes, concentrados en los vasos marcados por fluoroscopía y en el centellograma. La consigna sigue pidiendo lo de siempre, con los mismos datos y la misma semilla: qué modelo clasifica mejor, de qué tamaño queda y cuánto tarda. Este informe le suma otra pregunta. Qué se puede afirmar de esa diferencia cuando el árbol lo escribió el equipo, el bosque viene de una biblioteca y el faltante no se resolvió de la misma manera en los dos.

El árbol es propio. Para el bosque, el enunciado habilita un modelo de biblioteca y lo dice con esta grafía: “para el algoritmo RF se podrá utilizar un modelo de la libraría Scikit-learn”. El impacto que se reclama no es un criterio clínico nuevo. Es una comparación reproducible. Un caso se puede bajar por el árbol. El bosque se puede citar sin reescribirlo. El archivo queda como lo dejó el donante, con sus ceros y con sus huecos.

Cada sede tiene un investigador responsable, y el archivo pide que se los nombre. Son Andras Janosi (Instituto Húngaro de Cardiología, Budapest), William Steinbrunn (Hospital Universitario de Zúrich), Matthias Pfisterer (Hospital Universitario de Basilea) y Robert Detrano (Centro Médico de Long Beach

y Cleveland Clinic). David W. Aha donó el conjunto en julio de 1988. Detrano y sus coautores informaron, sobre sedes separadas, una discriminación logística de alrededor del 77 % [2]. Ese número es de ellos. Los de este informe salen de la corrida del 11 de noviembre de 2026.

Play Tennis e Iris no entran en la competencia. Sirven para mirar el mismo árbol cuando todo es categoría y cuando todo es continuo. Las Tablas 2 y 5, y las Figuras 4, 6, 7, 8, 9 y 10, conservan la numeración del notebook. Las Tablas 3 y 4 reúnen cifras que antes estaban sueltas en el texto. La Tabla 6 y la Figura 11 son la lectura del 12 de noviembre.

2. Algoritmos

2.1. Árbol

El árbol elige el corte con gain ratio: la ganancia de información dividida por la información de la partición. El cociente evita premiar a un atributo solo porque abre muchas ramas [4, p. 67]. Una categoría abre una rama por valor. Un continuo se parte en dos, con los valores menores o iguales al umbral de un lado y el resto del otro. Los candidatos son los puntos medios, entre valores ordenados, donde cambia la clase. En esta corrida, mirar solo esas fronteras devolvió los mismos umbrales que mirar todos los puntos medios. Después de usar un atributo, el árbol lo saca de la lista, también si era continuo. En cada rama hay un solo corte por columna. Esa decisión, y no una propiedad de los pacientes, es la que deja la altura clavada en 13.

Cuando falta el valor que parte el nodo, el caso no se completa con una moda ni se descarta. Se reparte entre las ramas conocidas, en proporción a la masa de cada una. Cada nodo guarda t, la proporción de valores conocidos. En una hoja, que ya no pregunta nada, t vale 1. El reparto, y el descuento de la ganancia por la proporción conocida, son de C4.5. Usar t dentro de la poda, para no tratar como plenamente observada una masa que llegó fraccionada, es una decisión del equipo. No forma parte de la rutina AddErrs.

La poda corre después de crecer, y solo si se la enciende. En cada nodo compara el error estimado de dejar el subárbol con el de reemplazarlo por una hoja. Si la hoja no es peor, el nodo se convierte en hoja. No hay otro movimiento: Quinlan también puede reemplazar el nodo por su rama más usada, y este código no lo hace. El error estimado sigue el listado AddErrs [6, pp. 278–279]. Interpola con el factor de confianza y, para 0,25, obtiene $z = 0{,}6925$. No usa la convención de la nota al pie del libro, que parte de la mitad de ese factor. Por defecto la poda está apagada. La comparación principal es ese árbol. La Tabla 5 la enciende a propósito.

2.2. Bosque

El bosque es el de Breiman [1]. Se toma de scikit-learn [5] y queda envuelto en `RandomForestWrap`, con la misma firma que el árbol: ajustar, predecir y devolver

probabilidades sobre un cuadro de atributos y un vector de clases. La corrida publicada usa cien árboles, la semilla 42, la raíz cuadrada de los atributos en cada corte, remuestreo y hoja mínima de uno, sin tope de profundidad.

El wrapper imputa. Las columnas numéricas se completan con la mediana y las categóricas con la moda; estas últimas se parten después en columnas binarias. Eso ocurre dentro del ajuste y de la predicción. El cuadro que ve el árbol no pasa por ahí. Los dos modelos reciben las mismas columnas y resuelven el hueco de dos maneras. Con los vasos y el centellograma ausentes en más de la mitad de las filas, esa diferencia forma parte del resultado.

3. Solución y problemas

Medir los dos modelos con una sola función obligó a cerrar el camino antes de mirar un número. El primer bosque se entrenaba como el árbol mínimo: recibía el cuadro completo y el nombre de la clase. El árbol de las tablas separa atributos y clase. Hasta que el bosque pasó a esa misma firma, el validador no podía llamar a los dos.

Otros controles medían otra cosa. La entropía lee etiquetas, no conteos: dos unos son la misma clase y valen cero bits. Se dejó la función y se corrigió el test. Un piso de 0,85 de accuracy para un solo corte continuo lo cumplía un atributo de Breast Cancer, el archivo de respaldo mientras el corazón no estaba armado. En Heart Disease ese corte separa los colesteroles en cero del resto y queda apenas sobre la línea de responder siempre presencia. El control pasó a informar el número, no a exigirlo. Un tercer control pedía que la poda no bajara la accuracy en el holdout. La poda decide mirando el entrenamiento. El control ahora admite una baja de hasta tres puntos y sigue exigiendo que el árbol salga con menos nodos.

El entorno cerró lo que faltaba para que la medición viera el árbol que el código dice construir. Pandas 3 guarda el texto en un tipo que el filtro de categorías no reconocía, y el árbol se quedaba sin esas columnas. Un nodo interno sin clase mayoritaria devolvía un vacío ante un valor nuevo. El texto pasó a contar como categoría, y todo nodo guarda la clase. El ROC de dos clases no acepta la firma de varias: el valor publicado es el promedio de una curva por clase (Figura 10). Si la predicción sale como texto, se rearma, para que una etiqueta numérica no se lea como destino desconocido.

Con eso cerrado, el árbol que se mide sigue en deuda con un C4.5 completo. Son tres decisiones, dejadas así para que no se las tome por olvido:

- Un atributo, también continuo, se usa una sola vez. C4.5 puede volver a cortarlo más abajo, con otro umbral.
- La poda reemplaza un subárbol por una hoja. No hace el reemplazo por la rama más usada.
- El factor t de la poda es del equipo. No hay que atribuirlo a AddErrs.

El criterio por defecto no exige un gain ratio mínimo. La hoja mínima vale uno, más permisiva que los dos casos de Quinlan. La poda viene apagada. Los

códigos de sexo, tipo de dolor, electrocardiograma, angina de esfuerzo, pendiente del ST, número de vasos y centellograma se tratan como categorías, no como magnitudes.

4. Metodología

La carga vive dentro del notebook. Junta los cuatro archivos procesados: Cleveland (303 filas), Hungría (294), Suiza (123) y Long Beach (200). El signo de pregunta queda como faltante. La clase original va de 0 a 4; el propio archivo de nombres dice que los experimentos separan ausencia (0) de presencia (1 a 4), y eso es lo que se hizo. Quedan 411 ausencias (44,7 %) y 509 presencias (55,3 %). Responder siempre presencia acierta, entonces, el 55,3 %. Hay 1759 faltantes. Los vasos faltan en el 66,4 % de las filas, el centellograma en el 52,8 % y la pendiente del ST en el 33,6 %. El colesterol 0 aparece 172 veces. El archivo no lo define como faltante, y se deja. La misma decisión se tomó con el mínimo 0 de la presión arterial, que no se recodificó.

La semilla es 42, y todo lo que usa azar la recibe de forma explícita. El validador repite cinco veces un pliegue estratificado de cinco. Son 25 scores, y rechaza otro tipo de partición. Estratificar cuida que ninguna de las dos clases desaparezca de un bloque. Esas 25 lecturas describen el comportamiento de los modelos. El cierre, para los valores por defecto, es un segundo corte: un holdout estratificado de 80/20, armado una sola vez, con 736 filas de entrenamiento y 184 de prueba.

Los barridos ven solo esas 736. Cada grilla mueve un parámetro y deja el resto en su valor por defecto. El elegido es el modelo más chico cuya accuracy media de prueba queda a menos de un desvío del máximo de esa grilla. Si la curva sigue subiendo hasta el extremo más complejo, no hay un óptimo asentado: se aplica igual la regla y se lo dice. Los parámetros se eligieron de a uno. Juntarlos después no es una búsqueda cruzada. El holdout de esa combinación se mide una vez y no vuelve a usarse para elegir. La comparación entre árbol y bosque sigue siendo el F1 macro. La regla de la grilla mira accuracy. Son dos decisiones, y se nombran aparte.

La Tabla 2, la Tabla 5 y la Figura 7 se calcularon sobre las 920 filas. La corrida que las produjo usó cuatro procesos. Con ocho, la máquina de 8 GB se quedaba sin memoria y el cruce se frenaba. El particionador no cambió.

5. Resultados

En F1 macro el bosque queda arriba: $0{,}8157 \pm 0{,}0308$ contra $0{,}7809 \pm 0{,}0271$ del árbol. También queda arriba en accuracy y en ROC-AUC, y se ajusta en una fracción del tiempo. El árbol necesita del orden de cincuenta segundos por partición; el bosque, menos de medio. A cambio, el árbol cabe en 452 nodos y el bosque suma cerca de veintinueve mil entre sus cien árboles. La altura del árbol es 13, con desvío cero: trece atributos, una vez cada uno, en el camino más largo. El resto de las métricas está en la Tabla 2 y en la Figura 4.

Tabla 2. DT y RF: media y desvío en las 25 particiones.

métrica	DT media	DT desvío	RF media	RF desvío
accuracy	0.7850	0.0265	0.8187	0.0305
precision macro	0.7848	0.0275	0.8185	0.0317
precision weighted	0.7856	0.0269	0.8192	0.0307
recall macro	0.7796	0.0270	0.8145	0.0303
recall weighted	0.7850	0.0265	0.8187	0.0305
F1 macro	0.7809	0.0271	0.8157	0.0308
F1 weighted	0.7840	0.0266	0.8182	0.0304
ROC-AUC	0.8195	0.0295	0.8839	0.0254
tiempo de ajuste (s)	50.5863	9.7970	0.4842	0.0406
tiempo de predicción (s)	0.1510	0.0324	0.1355	0.0228
nodos	452.0000	36.4406	28876.4800	664.6569
hojas	247.3600	18.6299	14488.2400	332.3284
altura	13.0000	0.0000	23.0400	1.3064

Las grillas, medidas solo sobre el entrenamiento, cuentan otra historia. Tres siguen subiendo en el extremo más complejo: la profundidad, el gain ratio mínimo y la cantidad de árboles. Llamar «óptimo» a profundidad 2, a un gain ratio de 0,1 o a diez árboles diría más de lo que la regla autoriza. La regla pide el modelo más chico dentro de la banda, y en esos tres casos la banda llega hasta el final. La hoja mínima y la cantidad de atributos por corte sí se frenan. La Figura 6 muestra la primera de esas curvas. La Tabla 3 reúne las cinco decisiones.

Tabla 3. Grillas de un solo parámetro, sobre las 736 filas de entrenamiento. La accuracy es la de prueba. Se elige el modelo más chico a menos de un desvío del máximo.

Parámetro	Elegido	Accuracy	Lectura de la curva
Profundidad	2	$0{,}7286 \pm 0{,}0344$	Sigue hasta el árbol sin tope (0,7677)
Hoja mínima	50	$0{,}7653 \pm 0{,}0321$	El máximo está en cinco casos (0,7772)
Gain ratio mínimo	0,1	$0{,}7432 \pm 0{,}0293$	Sigue hasta el umbral nulo; con 0,2 queda un nodo (0,5530)
Cantidad de árboles	10	$0{,}7859 \pm 0{,}0347$	Sigue hasta 200 árboles (0,8134)
Atributos por corte	`log2`	$0{,}8093 \pm 0{,}0354$	El máximo es la raíz cuadrada

Esos cinco valores se eligieron de a uno. Juntos, y una sola vez, enfrentan las 184 filas que no participaron de la elección. El bosque por defecto conserva la ventaja: su F1 macro en el holdout queda por encima del bosque chico que armó la regla. La Tabla 4 pone las dos lecturas lado a lado. En esas 184 filas hay 82 ausencias y 102 presencias. El árbol se equivoca en el 30,5 % de las ausencias y en el 13,7 % de las presencias. El bosque baja esas tasas al 18,3 % y al 9,8 %. El

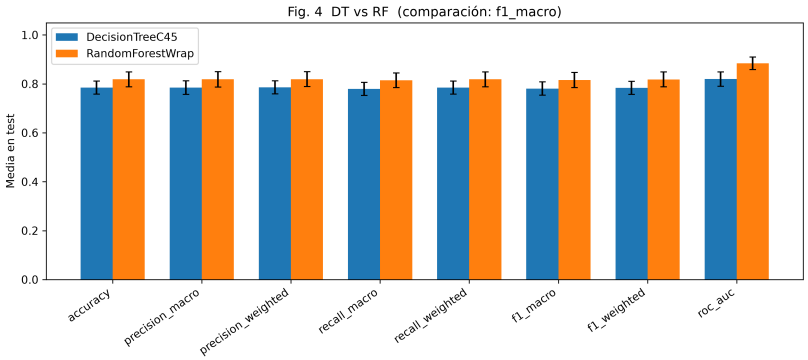


Figura 4. Métricas de prueba, media y desvío, en las 25 particiones.

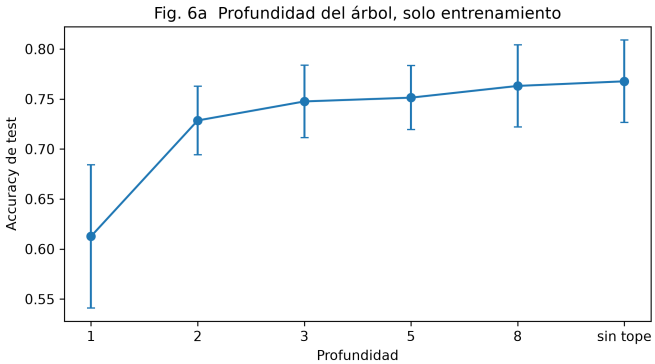


Figura 6. Accuracy de prueba según la profundidad, solo sobre el entrenamiento. La curva sigue subiendo al quitar el tope.

error de los dos se concentra en marcar enfermedad donde no la hay, y el bosque lo reduce en las dos clases. Las Figuras 9 y 10 salen de este corte.

Tabla 4. Holdout de la semilla 42: 736 filas de entrenamiento y 184 de prueba. Las filas de la grilla juntan parámetros elegidos de a uno. No son una búsqueda cruzada.

Modelo	Accuracy	F1 macro	ROC-AUC
Árbol por defecto	0,7880	0,7819	0,8192
Bosque por defecto	0,8641	0,8616	0,9219
Árbol de la grilla	0,7935	0,7926	0,8057
Bosque de la grilla	0,8370	0,8336	0,8923

La poda se juzga por la media de las 25 particiones, no por un corte afortunado. Ahí el árbol baja de 452 nodos a 71,2, la brecha de accuracy se achica y la accuracy de prueba cede cerca de un punto. El bosque, en la misma figura, memoriza el entrenamiento y por eso su brecha queda más ancha, aun con una prueba mejor. La Tabla 5 y la Figura 7 tienen el detalle. En el holdout de la misma semilla la poda vuelve a achicar el árbol, de 448 nodos a 71, y la accuracy de prueba esta vez sube, de 0,7880 a 0,7989. El 90,2 % de las predicciones de ese corte no cambia. Exigir al menos diez casos por hoja, en ese mismo corte, deja la prueba en 0,8370. Sigue siendo un solo corte. La decisión de podar se lee en la media.

Tabla 5. DT con poda pesimista y sin poda: media y desvío en 25 particiones.

métrica	sin poda media	sin poda desvío	con poda media	con poda desvío
nodos	452.0000	36.4406	71.2000	15.7374
hojas	247.3600	18.6299	39.0400	8.4335
altura	13.0000	0.0000	8.8400	0.8981
accuracy train	0.9285	0.0086	0.8663	0.0151
accuracy test	0.7850	0.0265	0.7741	0.0284
brecha	0.1435	0.0310	0.0922	0.0353

La curva de aprendizaje pregunta si hacía falta todo el entrenamiento. Con una fracción de las 736 filas el bosque ya está cerca de su mejor prueba, y al usarlas todas no sigue subiendo. El árbol se estabiliza antes y más abajo. La Figura 8 es esa curva. El peso que cada modelo le da a las columnas tampoco coincide. El bosque carga sobre todo en el tipo de dolor de pecho. El árbol pregunta muchas veces por la angina de esfuerzo y una sola por el tipo de dolor: la primera pregunta de un holdout puede ser la edad, y esa columna no vuelve a usarse.

El mejor corte de una sola columna cae en el colesterol, en el umbral 42,50, entre los ceros y el resto de los valores. No se lee como un límite clínico. Es la marca de un cero que se decidió conservar.

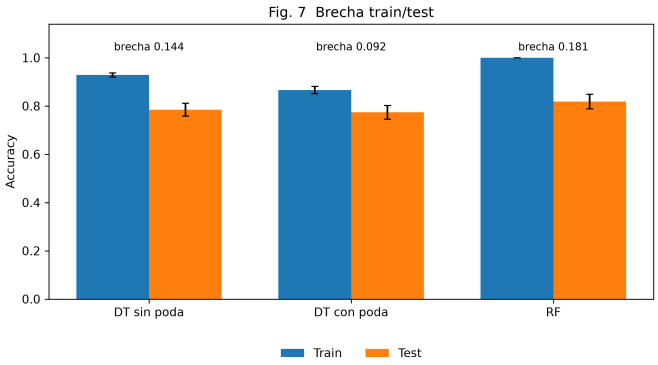


Figura 7. Accuracy de entrenamiento y de prueba. La brecha es la diferencia de las medias.

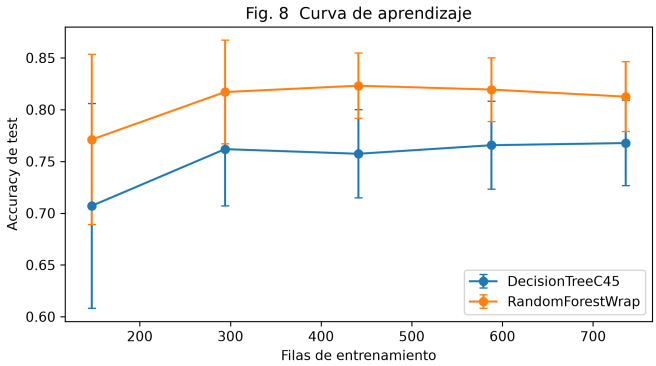


Figura 8. Accuracy de prueba según las filas de entrenamiento.

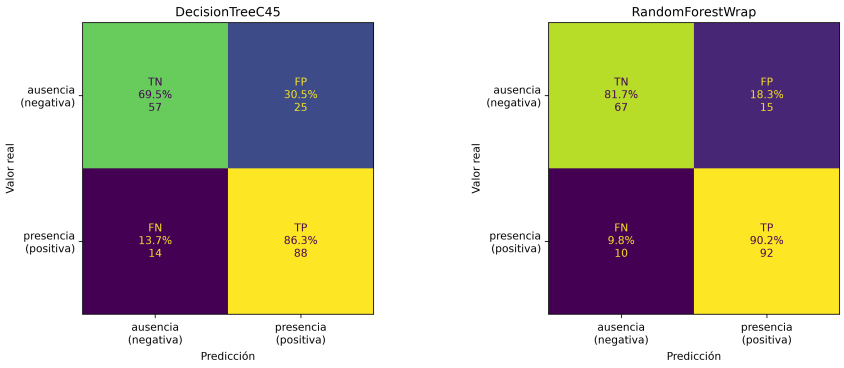


Figura 9. Matrices de confusión del holdout, normalizadas por fila. La clase positiva es presencia.

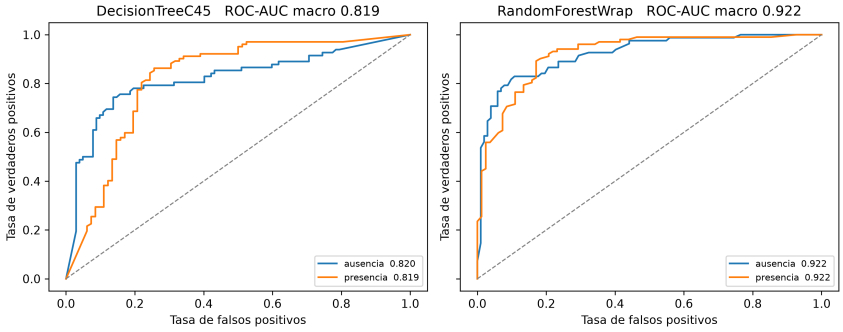


Figura 10. Curva ROC por clase en el holdout. El título de cada panel es el ROC-AUC macro.

6. Discretos, continuos y mixtos

El 12 de noviembre se dejó el mismo árbol por defecto, con la misma semilla, frente a un archivo de cada tipo. El código no elige el corte por el nombre de la columna. Mira el valor: el texto y el bool son categorías, un entero con hasta diez valores distintos es un código, y el resto numérico es continuo. Play Tennis e Iris no rehacen la Tabla 2. En esos dos el tamaño es el de un ajuste con todas las filas. En Heart Disease, los nodos, la altura y el F1 de la Tabla 6 son las medias ya publicadas.

Play Tennis trae catorce días, cuatro categorías y ningún faltante. Nueve se juegan y cinco no. El árbol los separa a todos. La primera pregunta es el cielo. Si está nublado, se juega. Si llueve, mira el viento. Si está soleado, mira la humedad. La temperatura no entra: con las otras tres columnas las catorce filas ya quedan puras. Cada categoría abre su rama y no se vuelve a usar. Al dejar un día afuera, el árbol acierta doce de catorce. La Figura 11 es ese ajuste, chico lo suficiente como para verse entero.

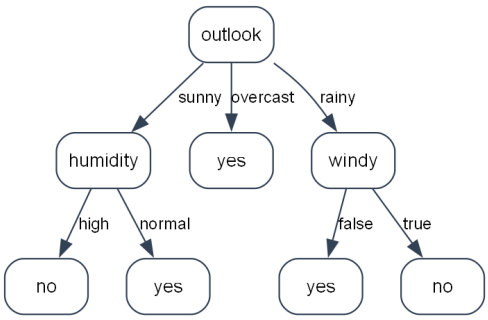


Figura 11. Árbol por defecto sobre las 14 filas de Play Tennis. Las ramas son los valores de la categoría.

Iris trae ciento cincuenta flores, cincuenta de cada especie, y cuatro medidas continuas. El ajuste usa las cuatro, una vez cada una, y la altura queda en cuatro: no puede ser otra, porque un continuo no se vuelve a cortar. La primera pregunta es el largo del pétalo, y de un lado de ese corte la hoja ya es setosa. La accuracy de ese ajuste no llega a uno. Cuatro flores quedan del lado de otra especie, y no hay un segundo umbral de la misma columna para rescatarlas. En las 25 particiones del protocolo, la ventaja del bosque entra en el desvío. La Tabla 6 tiene el F1.

Heart Disease mezcla los dos cortes y agrega los 1759 faltantes. Cinco columnas son continuas y ocho son códigos. El árbol abre una rama por código y un umbral por continuo, y después saca la columna. Por eso la altura media es 13, con desvío cero, y la accuracy de entrenamiento no llega a uno: pesan el corte

único y la masa repartida. En el holdout ya citado, el de 448 nodos, la primera pregunta es la edad, en el umbral 30,50.

Tabla 6. El mismo árbol por defecto en cada tipo de datos. El F1 de Iris y el de Heart Disease salen de las 25 particiones.

Conjunto	Corte	Filas	Nodos	Altura	Ajuste	Otra lectura
Play Tennis	4 categorías	14	8	2	1,0000	12 de 14
Iris	4 continuos	150	13	4	0,9733	F1 $0{,}9518 \pm 0{,}0349$
Heart Disease	5 continuos, 8 códigos	920	452	13	0,9285	F1 $0{,}7809 \pm 0{,}0271$

7. Discusión

El bosque gana el F1 macro, la accuracy y el ROC-AUC, y se ajusta en una fracción del tiempo. El holdout vuelve a darle la razón, también contra el bosque más chico que la regla de las grillas se animó a elegir. El árbol ofrece lo que el bosque no puede firmar: un camino. En Play Tennis ese camino cabe en una figura. En el corazón es largo, de altura 13, y aun así una fila se puede seguir hasta la hoja. El tamaño del bosque, cerca de veintinueve mil nodos, es el precio de la ventaja.

La poda se lee en la media de las 25 particiones. Achica el árbol a una fracción y achica la brecha. La accuracy de prueba, en esa media, baja. En el holdout de la misma semilla, sube. Publicar solo la que favorece sería esconder que la poda decide con el entrenamiento. Un corte solo no repite la media, y la media es la que manda.

Tres grillas no tienen un óptimo cerrado. Decirlo es parte del resultado. La regla del modelo más chico dentro de un desvío sigue siendo aplicable, y no convierte a profundidad 2, ni a diez árboles, en la última palabra. Esos valores, además, se eligieron de a uno. La combinación no mejora al bosque por defecto.

Los vasos y el centellograma faltan en más de la mitad de las filas, sobre todo fuera de Cleveland. El árbol reparte esa masa. El bosque la completa con la moda de las filas donde el valor sí está. Los dos reciben el mismo cuadro y no cuentan la misma historia del hueco. El colesterol en cero, dejado a propósito, alcanza para ser el mejor corte de una sola columna. Ese corte no se presenta como un umbral médico.

El tiempo tampoco se lee como una propiedad abstracta del algoritmo. El árbol está escrito en Python y prueba un umbral por frontera. El bosque llama a una implementación compilada. Los cincuenta segundos frente a menos de medio segundo son el costo de esta corrida, con cuatro procesos.

Donde todo es categoría y no falta nada, el ajuste se separa. Donde todo es continuo, la altura no pasa de la cantidad de columnas. En el mixto se suman las dos cosas y los faltantes. En Iris el F1 del bosque y el del árbol quedan dentro del desvío: la ventaja que muestran las tablas es la de Heart Disease.

8. Conclusiones

Sobre las cuatro sedes de Heart Disease, con clase binaria, semilla 42 y los valores por defecto, el bosque de scikit-learn supera al árbol del equipo en F1 macro, en accuracy y en ROC-AUC, y se ajusta mucho más rápido. El árbol queda en 452 nodos de altura 13. El bosque, en cerca de veintinueve mil. La diferencia se puede recorrer: un caso baja por preguntas; el otro se pierde en el voto de cien árboles. Las dos cosas son el resultado.

La poda pesimista, con factor de confianza 0,25, reduce el tamaño y la brecha. En las 25 particiones la accuracy media de prueba baja. En el holdout de la misma semilla, sube. El informe se queda con las dos lecturas. Los barridos se hicieron solo sobre el entrenamiento. Donde la curva sigue subiendo, el valor elegido por la regla del más chico no queda como un óptimo cerrado, y la combinación de esos valores no mejora al bosque por defecto.

El árbol implementa gain ratio, umbrales continuos en la frontera de clase, faltantes fraccionarios y la estimación AddErrs. Sigue en deuda con un C4.5 completo en tres puntos que este texto no esconde: un solo corte por atributo, poda sin reemplazo por la rama más usada, y un factor t propio. Con ese mismo código, un conjunto de categorías se separa en el ajuste, uno de continuos queda con altura igual a la cantidad de columnas, y el archivo clínico muestra las dos cosas junto con los faltantes. Eso es lo que el trabajo puede defender.

Referencias

1. Breiman, L.: Random forests. Machine Learning **45**(1), 5–32 (2001)
2. Detrano, R., Janosi, A., Steinbrunn, W., Pfisterer, M., Schmid, J., Sandhu, S., Guppy, K., Lee, S., Froelicher, V.: International application of a new probability algorithm for the diagnosis of coronary artery disease. American Journal of Cardiology **64**, 304–310 (1989)
3. Janosi, A., Steinbrunn, W., Pfisterer, M., Detrano, R.: Heart disease. UCI Machine Learning Repository (1988), donante: David W. Aha
4. Liu, B.: Web Data Mining: Exploring Hyperlinks, Contents, and Usage Data. Springer, 2 edn. (2011)
5. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., Duchesnay, É.: Scikit-learn: Machine learning in Python. Journal of Machine Learning Research **12**, 2825–2830 (2011)
6. Quinlan, J.R.: C4.5: Programs for Machine Learning. Morgan Kaufmann, San Mateo, CA (1993)